

IE-0629 Sistemas de Comunicación

Portafolio I – Reporte Ejecutivo

Edgar Alvarado Taleno
Carné: C10351

5 de octubre de 2026

Docente: Rodrigo Chacón Quesada

1. Resumen Ejecutivo

El Portafolio I estudia la aplicación de técnicas de aprendizaje automático (ML) a diferentes problemas de comunicaciones digitales, comparando su desempeño con métodos convencionales y relacionándolo con variables físicas del canal. Se analizaron cinco escenarios: clasificación automática de modulaciones, predicción de esquemas MCS en IEEE 802.11, decodificación de códigos convolucionales, estimación de canal OFDM y detección de símbolos OFDM. Los resultados muestran que el desempeño de ML depende fuertemente del problema y del régimen de operación. En clasificación, los modelos MLP superaron a la regresión logística, alcanzando mejoras de 7.75 y 26.73 puntos porcentuales en NB1 y NB2, respectivamente. Sin embargo, en tareas donde existe una estructura matemática conocida, los métodos convencionales pueden ser superiores. El decodificador Viterbi presentó un desempeño muy superior al MLP en el código convolucional, mientras que en detección OFDM el MLP prácticamente igualó al detector convencional basado en centroides.

En estimación de canal, el beneficio de ML fue condicionado por el nivel de ruido: el MLP residual mejoró el NMSE global en 2.11 %, pero su ventaja se concentró en los niveles de SNR más bajos. En conjunto, los experimentos indican que ML constituye una herramienta complementaria a los métodos clásicos, especialmente cuando existen relaciones complejas o difíciles de modelar explícitamente, pero no representa una sustitución universal de las técnicas tradicionales.

2. Análisis Consolidado y Comparación Técnica

Los primeros dos experimentos evaluaron problemas de clasificación a partir de muestras I/Q. En NB1, la precisión aumentó de 0.2492 con regresión logística a 0.3267 con el MLP, equivalente a una mejora de 7.75 puntos porcentuales. En NB2, la mejora fue más pronunciada: la regresión logística alcanzó 0.1798 frente a 0.4471 del MLP, una diferencia de 26.73 puntos porcentuales. Estos resultados muestran la capacidad de las redes neuronales para representar relaciones no lineales entre las características de la señal y la clase de modulación o MCS.

Cuadro 1: Comparación de desempeño de los experimentos de clasificación.

Experimento	Método convencional	MLP	Mejora
NB1 – AMC	0.2492	0.3267	+7.75 pp
NB2 – MCS	0.1798	0.4471	+26.73 pp

El comportamiento cambia en tareas donde el modelo físico proporciona una estructura explícita para resolver el problema. En NB3 se comparó la decodificación de un código convolucional mediante Viterbi y un MLP. La Figura 1 muestra que Viterbi mantiene una BER considerablemente menor en todo el intervalo evaluado. A partir de 4 dB se obtuvieron cero errores en los 6400 bits evaluados por condición, mientras que el MLP pasó de una BER de 0.4688 a 0.0739 entre 0 y 10 dB. Esto evidencia que el conocimiento de la estructura del código permite a un algoritmo clásico explotar eficientemente la información disponible.




Figura 1: BER en función de E_b/N_0 para BPSK, Viterbi y MLP.

En NB4 se evaluó la estimación de canal OFDM mediante un MLP residual. El NMSE global pasó de 0.581362 para el estimador convencional a 0.569101 con ML, correspondiente a una mejora relativa de 2.11 %. Sin embargo, esta ventaja no fue uniforme con el SNR: el MLP superó al método convencional a -5 y 0 dB, mientras que el estimador tradicional obtuvo mejores resultados desde 5 dB. Por tanto, el valor de ML aumenta principalmente en condiciones donde la estimación convencional se encuentra más afectada por el ruido.




Figura 2: Comparación de NMSE entre el estimador convencional y el MLP residual.

Finalmente, NB5 utilizó datos reales obtenidos mediante SDR para la detección de símbolos 16-QAM. El detector convencional basado en centroides obtuvo una BER de 0.097835, mientras que el MLP obtuvo 0.097863. La diferencia de $2,8 \times 10^{-5}$ es despreciable experimentalmente, por lo que no se observó una ventaja práctica del modelo neuronal. Al analizar el canal en función del SINR, se observó el comportamiento físico esperado: al aumentar el SINR disminuye la dispersión de la constelación y la BER.




Figura 3: BER de la detección OFDM en función del SINR.

3. Interpretación Física y Consideraciones de Implementación

Los cinco experimentos permiten observar una relación consistente entre el desempeño de los algoritmos y la calidad física de la señal. En los experimentos de clasificación, la información contenida en las muestras I/Q permite al MLP aprender fronteras de decisión no lineales. En los problemas de canal y detección, las variables SNR y SINR determinan directamente la cantidad de perturbación presente en las observaciones. En general, una mejor calidad de señal facilita la recuperación de la información, aunque esto no implica necesariamente que ML supere a un método convencional.

La comparación entre NB3 y NB4 resulta especialmente importante. Viterbi dispone de un modelo explícito del código convolucional y utiliza su estructura de estados para realizar la decisión óptima bajo las condiciones del experimento. Por ello, el MLP requiere aprender mediante datos una relación que ya se encuentra incorporada en el algoritmo tradicional. En contraste, en estimación de canal el MLP puede complementar el estimador convencional al aprender patrones residuales que no son capturados completamente por el método tradicional.

También deben considerarse los costos computacionales. En NB2, el MLP utilizó 139 976 parámetros y requirió 74.61 s de entrenamiento, frente a 52.21 s de la regresión logística. En NB4, el MLP utilizado tuvo 16 576 parámetros. Estos resultados no permiten determinar directamente el consumo energético durante inferencia, ya que no se realizaron mediciones de potencia o energía. No obstante, muestran que una mejora de desempeño mediante ML debe evaluarse conjuntamente con memoria, procesamiento, latencia y energía, especialmente en dispositivos IoT o sistemas con recursos limitados.

Desde la perspectiva de comunicaciones, tampoco se midió directamente una reducción del ancho de banda o del consumo de transmisión. Por tanto, estos aspectos deben considerarse como restricciones de implementación y no como resultados experimentales del portafolio.

4. Conclusiones y Lecciones Aprendidas

Los experimentos realizados muestran que el aprendizaje automático puede aportar mejoras significativas en determinados problemas de comunicaciones, pero su utilidad depende de la estructura del problema, la calidad de los datos y las condiciones del canal. Las mayores mejoras se observaron en clasificación, especialmente en la predicción de MCS de NB2. En estimación de canal, el beneficio fue moderado y dependiente del SNR, mientras que en detección OFDM el MLP presentó un desempeño prácticamente equivalente al método convencional.

El caso de la decodificación convolucional demuestra que un modelo clásico especializado puede superar ampliamente a una red neuronal cuando existe un modelo físico o matemático bien definido. Por ello, la incorporación de ML no debe justificarse únicamente por su capacidad de aproximación, sino por la existencia de una ventaja concreta frente a una solución convencional.

Como lección principal, los resultados respaldan un enfoque híbrido en el que los métodos tradicionales aportan conocimiento físico y estructura, mientras que ML se utiliza para aprender relaciones complejas o compensar errores residuales. Para sistemas reales también deben considerarse latencia, memoria, capacidad de cómputo, consumo energético y restricciones de ancho de banda. Los experimentos realizados permiten concluir que ML es una herramienta viable y complementaria para sistemas de comunicación, pero su adopción debe realizarse de acuerdo con las características específicas de cada problema y régimen de operación.